
Optimasi Biaya Pemeliharaan melalui Pendekatan Prediktif dan Preskriptif untuk Efisiensi Maksimal

Josh Edward Sutanto
Bina Nusantara University
Tangerang, Indonesia
josh.sutanto001@binus.ac.id

Vincentius Jacob Gunawan
Bina Nusantara University
Tangerang, Indonesia
vincentius.gunawan002@binus.ac.id

Rizky Fadhilah
Bina Nusantara University
Tangerang, Indonesia
rizky.fadhilah@binus.ac.id

Abstrak

Tingginya biaya pemeliharaan mesin dari total biaya produksi, mendorong kebutuhan akan strategi pemeliharaan yang efisien untuk menjamin efisiensi biaya dan ketersediaan sistem. Laporan ini mengusulkan sebuah *Predictive Maintenance* (PdM) komprehensif yang memanfaatkan data dari mesin untuk memberikan informasi hal yang perlu dilakukan. Model prediksi yang dikembangkan pada laporan ini mampu untuk mengidentifikasi sebagian besar potensi kegagalan secara proaktif, tetapi juga memberikan diagnosis komponen yang akurat dan estimasi sisa umur pakai yang kuantitatif. Kerangka kerja terintegrasi ini memungkinkan transisi dari strategi pemeliharaan reaktif atau berbasis waktu yang mahal menuju pendekatan prediktif yang lebih cerdas dan efisien secara biaya, dengan menjawab pertanyaan krusial 'apakah', 'apa', dan 'kapan' sebuah mesin akan mengalami kegagalan.

1 Pendahuluan

Dalam lingkungan industri yang kompetitif, efisiensi dan ketersediaan sistem produksi merupakan faktor kunci untuk menjaga profitabilitas [1], [2]. Namun, biaya pemeliharaan seringkali menjadi beban finansial yang signifikan, bahkan dalam beberapa kasus dapat mencapai 15% hingga 70% dari total biaya produksi [3], [4]. Strategi pemeliharaan tradisional seperti *Preventive Maintenance* (PvM) atau pemeliharaan berbasis waktu, meskipun efektif, seringkali tidak optimal secara biaya karena dapat menyebabkan penggantian komponen yang tidak perlu atau sebaliknya, gagal mencegah kerusakan tak terduga [5]. Untuk mengatasi tantangan ini, strategi *Predictive Maintenance* (PdM) hadir sebagai pendekatan yang lebih cerdas, di mana tindakan pemeliharaan hanya dilakukan saat benar-benar dibutuhkan dengan tujuan meminimalkan biaya dan memaksimalkan ketersediaan sistem [6], [7]. Perkembangan teknologi informasi, khususnya *Machine Learning* (ML), menjadi pendorong utama dalam implementasi PdM. Algoritma ML mampu menganalisis data dalam jumlah besar yang dikumpulkan dari sensor mesin untuk mengidentifikasi pola-pola kompleks, mendeteksi anomali, dan memprediksi kegagalan yang akan datang. Meskipun potensinya besar, implementasi ML-based PdM merupakan proses yang kompleks dan mahal, yang menuntut adanya analisis berorientasi biaya untuk memvalidasi kelayakannya [8]. Proyek ini bertujuan untuk mengembangkan sebuah kerangka kerja PdM yang komprehensif, mulai dari tahap pengolahan data hingga pemodelan prediktif, dengan fokus pada

51 bagaimana hasil teknis dapat diterjemahkan menjadi wawasan bisnis yang dapat ditindaklanjuti.
52 Berdasarkan latar belakang tersebut, penelitian ini dirancang untuk menjawab beberapa
53 pertanyaan kunci: Bagaimana cara membangun sebuah *pipeline* data yang efektif untuk mengubah
54 data operasional mentah menjadi fitur-fitur prediktif yang bermakna? Bagaimana cara
55 mengembangkan model untuk memprediksi probabilitas kegagalan, mendiagnosis komponen
56 spesifik yang berisiko, serta mengestimasi sisa umur pakai (*Remaining Useful Life* - RUL) untuk
57 mendukung perencanaan pemeliharaan? Dan yang terpenting, bagaimana kerangka kerja yang
58 mengintegrasikan model-model prediksi ini dapat memberikan nilai dan wawasan dari perspektif
59 bisnis?

60 Untuk menjawab serangkaian permasalahan tersebut, penelitian ini menetapkan beberapa tujuan
61 spesifik. Tujuan utamanya adalah mengembangkan *pipeline* rekayasa fitur yang komprehensif,
62 lalu membangun dan mengevaluasi tiga model prediksi menggunakan algoritma XGBoost: (1)
63 model klasifikasi biner untuk probabilitas kegagalan, (2) model klasifikasi *multi-class* untuk
64 diagnosis komponen yang sekiranya gagal, dan (3) model regresi untuk estimasi RUL. Selain itu,
65 penelitian ini bertujuan untuk menyajikan sebuah kerangka kerja pemodelan dua tahap yang
66 mengintegrasikan model "Detector" (deteksi kegagalan) dan "Diagnoser" (diagnosis komponen)
67 sebagai solusi praktis untuk mendukung pengambilan keputusan yang proaktif.

68 Penelitian ini memiliki ruang lingkup terbatas pada dataset publik *Predictive Maintenance* dari
69 Microsoft Azure yang terdiri dari data telemetri, error, pemeliharaan, kegagalan, dan metadata
70 mesin. Implementasi model difokuskan pada penggunaan algoritma XGBoost, sementara analisis
71 biaya dilakukan secara konseptual karena tidak tersedianya data harga komponen dalam dataset
72 asli. Fokus bisnis ditekankan pada bagaimana output model dapat digunakan untuk pengambilan
73 keputusan yang lebih hemat biaya. Untuk menyajikan temuan ini secara sistematis, laporan ini
74 diorganisir ke dalam beberapa bab. Setelah pendahuluan ini, **Bab 2** akan menyajikan kajian teori
75 yang relevan. **Bab 3** akan menjelaskan metodologi dan solusi usulan secara rinci. **Bab 4** dan **Bab**
76 **5** akan memaparkan hasil eksperimen serta analisisnya. Terakhir, **Bab 6** akan menyajikan
77 kesimpulan dari seluruh rangkaian penelitian serta saran untuk pengembangan di masa depan.

78

79 **2 Kajian Teori**

80 Dalam bagian ini, kami akan menjelaskan **elemen penting** dari pendekatan yang kami gunakan.
81 Kami akan memulainya dengan gambaran umum.

82 **2.1 Perbandingan Strategi Pemeliharaan**

83 Pemilihan strategi pemeliharaan atau *maintenance* yang tepat merupakan faktor penting dalam
84 operasional industri. Biaya *maintenance* atau pemeliharaan merupakan salah satu komponen
85 pengeluaran yang relatif besar, maka dari itu diperlukan strategi pemeliharaan yang terbaik demi
86 profitabilitas perusahaan [9], [10]. Salah satu strategi yang paling umum digunakan adalah
87 *Preventive Maintenance* (PvM). PvM adalah strategi berbasis waktu atau *time-based* di mana
88 tindakan pemeliharaan dilakukan berdasarkan jadwal yang telah ditentukan [11]. Tujuannya adalah
89 untuk menyeimbangkan antara biaya dan pemeliharaan terencana dan biaya perbaikan untuk
90 menemukan titik paling optimal dalam melakukan *maintenance* [12]. Meskipun PvM merupakan
91 strategi yang efektif dan banyak dipakai, PvM memiliki kelemahan dimana seringkali penggunaan
92 strategi ini kurang optimal karena tidak mempertimbangkan kondisi dinamis dari peralatan. Hal ini
93 dapat menyebabkan biaya tambahan akibat penggantian komponen yang tidak perlu, error maupun
94 mesin yang rusak juga dapat terjadi di luar jadwal pemeliharaan sehingga strategi pemeliharaan ini
95 kurang efektif [13].

96

97 Sebagai solusi dari keterbatasan PvM, strategi *Predictive Maintenance* (PdM) hadir sebagai
98 pendekatan yang berbasis kondisi atau *condition-based* [14]. Tujuan dari PdM adalah untuk
99 mencegah error maupun *failure* yang akan datang lebih awal berdasarkan data dari komponen.
100 Dengan begitu, tindakan *maintenance* hanya akan dilakukan jika diperlukan sehingga
101 memungkinkan perusahaan untuk menghemat *maintenance budget* karena proses *maintenance*
102 yang sangat optimal [15].

103

2.2 Predictive Maintenance dan Relevansinya dalam Industri

Pada era industri modern, persaingan ketat antar perusahaan tidak hanya penting mengutamakan kualitas produk, akan tetapi penting juga mengutamakan efisiensi operasional. Efisiensi operasional dan keberlanjutan industri modern sangat bergantung pada **pemeliharaan mesin** yang efektif. Strategi tradisional seperti *run-to-failure* dan *preventive maintenance* kerap memicu *downtime* tak terduga dan kegagalan fatal. Menjawab tantangan ini, penting untuk memahami **Prognostics and Health Management (PHM)** sebagai fondasi **Predictive Maintenance (PdM)**. PdM memanfaatkan data dan teknologi canggih untuk **memprediksi potensi kerusakan** (prognosis) dan **menganalisis kondisi aset** (diagnosis), mengubah pendekatan pemeliharaan dari reaktif menjadi proaktif. [16] menegaskan bahwa PHM dan PdM penting dalam mewujudkan *smart manufacturing* [17], serta menekankan peran krusial **data** dalam PdM untuk akurasi prediksi *Remaining Useful Life* (RUL) di era digital ini.

2.3 Metodologi Prediksi Remaining Useful Life (RUL)

Prediksi *Remaining Useful Life* (RUL) merupakan salah satu komponen dari *Predictive Maintenance* (PdM), yang bertujuan untuk mengestimasi sisa umur pakai suatu komponen sebelum terjadinya “failure”. Kemampuan untuk memprediksi RUL secara akurat ini memungkinkan perusahaan untuk mengoptimalkan jadwal *maintenance* sehingga dana yang dialokasikan ke bagian ini dapat diminimalisir. Beberapa penelitian telah mengembangkan model prediksi RUL dengan memanfaatkan pendekatan berbasis data.

Secara umum, metode prediksi RUL berbasis data dibagi ke dalam 2 kategori yaitu metode statistik/*machine learning* dan metode *deep learning*. Metode klasik seperti *Support Vector Machine* (SVM) maupun *Random Forest* (RF) telah dieksplorasi. Namun, beberapa tahun terakhir, fokus penelitian bergeser signifikan ke arsitektur *deep learning* yang dapat menangkap pola yang lebih kompleks, menggunakan model seperti *Convolutional Neural Networks* (CNN), *Long Short-Term Memory* (LSTM), dan lain-lain.

Sebuah studi oleh Susana Margarida da Silva Vieira Jô ao et al (2021) melakukan perbandingan antara RF, XGBoost, LSTM, dan BiLSTM pada dataset mesin pesawat N-CMAPSS. Hasilnya menunjukkan bahwa model sekuensial (*deep learning*) secara signifikan mengungguli model klasik. Model BiLSTM memberikan performa terbaik dengan skor 2068 dan *Root Mean Squared Error* (RMSE) sebesar 20.9, diikuti oleh LSTM dengan skor 2744 dan RMSE 22.3. Sebagai perbandingan, XGBoost hanya mencapai skor 7513 dengan RMSE 39.8, menunjukkan keunggulan model yang mampu memahami urutan waktu [18]. Temuan serupa juga dilaporkan dalam penelitian oleh Guido Maxim van der Horst (2020), yang secara langsung membandingkan CNN dan LSTM untuk estimasi RUL pada dataset industri. Studi tersebut menyimpulkan bahwa model LSTM secara substansial dan signifikan lebih unggul daripada CNN. Pada salah satu pengujiannya, LSTM mencapai RMSE sebesar 15.01, sementara CNN hanya mencapai RMSE sebesar 22.06 pada tugas yang sama. Keunggulan LSTM dan variannya dalam menangani data sekuensial juga ditegaskan dalam berbagai survei literatur, baik untuk aplikasi umum maupun domain spesifik seperti baterai lithium-ion [19].

Meskipun model *deep learning* menunjukkan kinerja yang superior, implementasinya menghadapi tantangan, terutama terkait interpretasi. Model seperti LSTM seringkali berfungsi sebagai “kotak hitam”, di mana proses pengambilan keputusannya sulit untuk dipahami oleh manusia. Kurangnya transparansi ini dapat menjadi penghalang untuk adopsi di industri yang menuntut kepercayaan dan pemahaman terhadap prediksi. Hal ini mendorong tumbuhnya bidang penelitian *Explainable Artificial Intelligence* (XAI), yang bertujuan untuk mengembangkan teknik yang dapat memberikan penjelasan atas hasil prediksi dari model yang kompleks, sehingga membangun kepercayaan dan memfasilitasi adopsi yang lebih luas dalam aplikasi industri kritis [20].

2.4 Tantangan dalam Implementasi Model PdM

Meskipun *Predictive Maintenance* (PdM) berbasis *Machine Learning* (ML) menawarkan potensi keuntungan yang besar, implementasinya di dunia nyata penuh dengan tantangan yang signifikan. Proses ini bukan sekadar menerapkan algoritma pada data, melainkan sebuah inisiatif strategis yang kompleks. Beberapa studi memaparkan tantangan utama yang dapat dikategorikan ke dalam

tantangan terkait data, pemodelan, dan implementasi organisasional. Salah satu tantangan paling fundamental adalah terkait data. Ketersediaan data historis yang berkualitas tinggi sangat diperlukan untuk membangun model yang baik. Seringkali, perusahaan tidak memiliki data *run-to-failure* yang cukup, yaitu catatan data lengkap dari kondisi sehat hingga sebuah komponen benar-benar mengalami eror atau *failure*. Selain itu, data yang ada dapat berasal dari berbagai sumber dengan format yang berbeda, seperti data sensor terstruktur dan catatan pemeliharaan yang tidak terstruktur, yang memerlukan proses validasi dan pembersihan yang akurat dan intensif. Tantangan berikutnya terletak pada proses pemodelan itu sendiri. Mengubah data sensor mentah menjadi fitur prediktif yang bermakna adalah prosedur yang kompleks. Masalah lain yang sering muncul adalah sifat data *failure* yang tidak seimbang (*imbalanced*). Kejadian komponen eror maupun gagal jauh lebih jarang daripada kondisi operasi normal, yang dapat menyebabkan model menjadi bias dan cenderung memprediksi kondisi "aman", sehingga kehilangan akurasi dalam mendeteksi anomali yang sebenarnya. Oleh karena itu, diperlukan teknik penanganan khusus untuk memastikan model dapat belajar dari kelas minoritas yang krusial ini. Terakhir, terdapat tantangan signifikan dalam implementasi dan adopsi organisasional. Implementasi ML-based PdM adalah proses yang sulit dan mahal, yang melibatkan investasi besar dalam infrastruktur IT, sensor, dan sistem komputasi. Banyak perusahaan seringkali kekurangan keterampilan yang diperlukan, seperti ilmuwan data dan insinyur proses, untuk mengembangkan dan memelihara model-model ini. Lebih dari itu, salah satu penghalang terbesar untuk adopsi adalah sifat *black box* dari banyak model ML yang canggih. Kurangnya transparansi mengenai bagaimana model sampai pada suatu kesimpulan dapat menyebabkan kurangnya kepercayaan dari para manajer dan insinyur. Hal ini mendorong tumbuhnya bidang penelitian *Explainable Artificial Intelligence* (XAI), yang bertujuan untuk membuat keputusan model menjadi lebih dapat dipahami dan dipercaya oleh manusia.

3 Solusi Usulan

Solusi yang diusulkan dalam penelitian ini adalah sebuah kerangka kerja *Predictive Maintenance* (PdM) komprehensif yang dirancang untuk memberikan wawasan yang dapat ditindaklanjuti secara bisnis. Kerangka kerja ini mencakup beberapa tahapan utama, mulai dari pengumpulan dan pengolahan data mentah, *feature engineering* untuk mengekstrak sinyal prediktif, hingga pengembangan arsitektur model dua tahap untuk memprediksi probabilitas kegagalan dan mendiagnosis komponen spesifik yang berisiko. Pendekatan ini selaras dengan konsep *Decision Support System* (DSS) yang bertujuan untuk memandu implementasi PdM dari perspektif biaya dan manfaat.

3.1 Pre-processing data

Tahap awal dalam *pipeline* ini adalah pengumpulan dan pemrosesan data dari lima sumber yang tersedia: telemetri, eror, riwayat pemeliharaan, data kegagalan, dan metadata mesin. Langkah-langkah *pre-processing* yang dilakukan adalah sebagai berikut:

1. **Data Loading:** Kelima file CSV dimuat ke dalam struktur data *DataFrame* menggunakan pustaka *pandas*. Pada tahap ini, kolom yang berisi informasi tanggal dan waktu (*datetime*) langsung dikonversi menjadi tipe data *datetime64[ns]* menggunakan parameter *parse_dates*. Konversi ini krusial untuk memungkinkan semua operasi berbasis waktu di langkah-langkah selanjutnya.
2. **Handle duplicates:** Data telemetri mentah berpotensi memiliki beberapa catatan untuk mesin yang sama pada waktu yang identik. Untuk memastikan integritas data, dilakukan agregasi dengan mengelompokkan data berdasarkan *datetime* dan *machineID*, lalu menghitung nilai rata-rata (*mean*) untuk setiap sensor. Langkah ini menghasilkan satu catatan unik untuk setiap mesin pada setiap stempel waktu, yang sangat penting untuk analisis deret waktu yang akurat.

3.2 Feature Engineering

Setelah data dibersihkan, tahap selanjutnya adalah dilakukannya *feature engineering* untuk mengubah data mentah menjadi variabel prediktif yang informatif.

- 215 1. **Fitur Telemetri (*Rolling Statistics*):** Untuk menangkap kondisi dan stabilitas mesin
216 terkini, fitur deret waktu dihitung dari data telemetri. Data telemetri di-*resample* ke dalam
217 jangka waktu 3 jam untuk mengelola volume data. Kemudian, jangka waktu bergerak
218 (*rolling window*) selama 24 jam digunakan untuk menghitung statistik berikut untuk
219 setiap sensor (volt, rotate, pressure, vibration):
- 220 a. **Rata-rata Bergerak (*Rolling Mean*):** Menunjukkan nilai tren atau pusat dari
221 sinyal sensor dalam 24 jam terakhir.
- 222 b. **Standar Deviasi Bergerak (*Rolling Standard Deviation*):** Mengukur volatilitas
223 atau ketidakstabilan sinyal sensor. Nilai yang tinggi menandakan kondisi mesin
224 yang tidak stabil.
- 225 c. Setiap celah data (NaN) yang muncul akibat proses *resampling* diisi
226 menggunakan metode *forward fill* (`ffill()`) untuk memastikan kontinuitas data.
- 227 2. **Fitur Error (*Error Counts*):** Untuk mengukur frekuensi kejadian error, kolom errorID
228 diubah menjadi format numerik menggunakan *one-hot encoding* (`pd.get_dummies`).
229 Hasilnya kemudian dikelompokkan berdasarkan machineID dan di-*resample* ke frekuensi
230 harian (24H) dengan menjumlahkan kejadian setiap tipe error. Ini menghasilkan fitur
231 seperti `error1_count_24h`, `error2_count_24h`, dst.
- 232 3. **Fitur Pemeliharaan (*Maintenance History*):** Dengan pendekatan yang sama seperti fitur
233 error, riwayat penggantian komponen (`comp`) diubah menjadi fitur numerik yang
234 menghitung jumlah penggantian untuk setiap komponen per hari untuk setiap mesin.
- 235 4. **Fitur Statis Mesin:** Informasi statis dari `PdM_machines.csv`, yaitu model dan age (umur
236 mesin), digabungkan ke dalam dataset fitur utama menggunakan machineID sebagai
237 kunci. Umur mesin merupakan prediktor penting karena komponen cenderung
238 mengalami keausan seiring waktu.

239 3.3 Labeling

240 Setelah semua fitur dibuat, fitur-fitur tersebut digabungkan menjadi satu DataFrame final.
241 Langkah selanjutnya adalah membuat variabel target (label) untuk kedua model prediksi:

- 242 1. **Label Biner (Model Detektor):** Dibuat kolom `label_binary_failure`. Kolom ini diberi
243 nilai 1 untuk setiap titik data yang berada dalam jangka waktu 7 hari sebelum waktu
244 kegagalan yang tercatat di `PdM_failures.csv`. Semua titik data lainnya diberi nilai 0. Ini
245 mengubah masalah menjadi klasifikasi biner: "akankah mesin ini gagal dalam 7 hari ke
246 depan?".
- 247 2. **Label Multi-Kelas (Model Diagnoser):** Dibuat kolom `label_multi_comp`. Untuk titik
248 data dalam jangka 7 hari sebelum kegagalan, kolom ini diisi dengan nama komponen
249 yang gagal (misalnya, `comp1`, `comp2`). Semua titik data lainnya diberi label 'No_Failure'.
250 Label string ini kemudian diubah menjadi format integer menggunakan `LabelEncoder`
251 dari `scikit-learn`.

252 3.4 Pemodelan dan Evaluasi

253 Pendekatan pemodelan dua tahap diusulkan untuk memberikan prediksi yang komprehensif.

- 254 1. **Pembagian Data:** Dataset dibagi menjadi *training set* (80%) dan *test set* (20%) secara
255 **kronologis**, bukan acak. Hal ini penting untuk mensimulasikan skenario dunia nyata di
256 mana model dilatih pada data masa lalu untuk memprediksi masa depan, sehingga
257 mencegah *data leakage*.
- 258 2. **Model 1: Detektor Kegagalan (Klasifikasi Biner):**
- 259 a. **Algoritma:** `XGBClassifier` digunakan untuk memprediksi probabilitas
260 kegagalan.
- 261 b. **Penanganan Imbalance:** Karena jumlah data "gagal" jauh lebih sedikit
262 daripada "tidak gagal", parameter `scale_pos_weight` digunakan untuk
263 memberikan bobot yang lebih tinggi pada kelas minoritas (kegagalan) selama
264 pelatihan.
- 265 c. **Tujuan:** Menghasilkan skor risiko yang dapat digunakan untuk
266 memprioritaskan mesin mana yang memerlukan perhatian.

- 267 **3. Model 2: Diagnoser Komponen (Klasifikasi Multi-Kelas):**
- 268 a. **Algoritma:** XGBClassifier dikonfigurasi untuk klasifikasi multi-kelas dengan
- 269 objective='multi:softprob'.
- 270 b. **Pelatihan:** Model ini dilatih **hanya pada data yang berlabel "gagal"** dari set
- 271 pelatihan. Tujuannya adalah untuk mengajarkan model cara membedakan tanda-
- 272 tanda kegagalan antar komponen yang berbeda.
- 273 c. **Tujuan:** Ketika Model 1 menandai sebuah mesin sebagai berisiko tinggi, model
- 274 ini digunakan untuk mendiagnosis komponen mana yang kemungkinan besar
- 275 akan gagal.
- 276 4. **Metrik Evaluasi:** Kinerja model dievaluasi menggunakan metrik standar klasifikasi.
- 277 **Confusion Matrix** (atau "error matrix" seperti yang dibahas dalam literatur) digunakan
- 278 untuk memahami jenis kesalahan yang dibuat model. Laporan klasifikasi yang mencakup
- 279 **Precision**, **Recall**, dan **F1-score** juga dianalisis. Dalam konteks PdM, **Recall** menjadi
- 280 metrik yang sangat penting karena kita ingin memaksimalkan kemampuan model untuk
- 281 menangkap sebanyak mungkin kegagalan yang sebenarnya, bahkan jika itu menghasilkan
- 282 beberapa peringatan palsu.

284 **4 Hasil Eksperimen dan Pengujian**

285 **5 Analisis Hasil**

286

287 **Referensi**

- 288 [1] Alexander, J.A. & Mozer, M.C. (1995) Template-based algorithms for connectionist rule
- 289 extraction. In G. Tesauro, D. S. Touretzky and T.K. Leen (eds.), *Advances in Neural Information*
- 290 *Processing Systems* 7, pp. 609-616. Cambridge, MA: MIT Press.
- 291 [2] Bower, J.M. & Beeman, D. (1995) *The Book of GENESIS: Exploring Realistic Neural Models with*
- 292 *the GEneral NEural SIEmulation System*. New York: TELOS/Springer-Verlag.
- 293 [3] Hasselmo, M.E., Schnell, E. & Barkai, E. (1995) Dynamics of learning and recall at excitatory
- 294 recurrent synapses and cholinergic modulation in rat hippocampal region CA3. *Journal of*
- 295 *Neuroscience* **15**(7):5249-5262.
- 296 [4] Lee, J., Wu, F., Zhao, W., Ghaffari, M., Liao, L., & Siegel, D. (2014). Prognostics and health
- 297 management design for rotary machinery systems - Reviews, methodology and applications. *Mechanical*
- 298 *Systems and Signal Processing*, 42(1–2), 314–334. <https://doi.org/10.1016/j.ymssp.2013.06.004> (INI
- 299 GATAU KENAPA PAS KE CITATION JADI NO 1 DI KAJIAN TEORI)
- 300
- 301 [5] Achouch, M., Dimitrova, M., Ziane, K., Sattarpanah Karganroudi, S., Dhouib, R., Ibrahim, H., & Adda,
- 302 M. (2022). On Predictive Maintenance in Industry 4.0: Overview, Models, and Challenges. In *Applied*
- 303 *Sciences (Switzerland)* (Vol. 12, Issue 16). MDPI. <https://doi.org/10.3390/app12168081> (INI GATAU
- 304 KENAPA PAS KE CITATION JADI NO 2 DI KAJIAN TEORI)

305

306